



中国科学院大学

University of Chinese Academy of Sciences

模式识别与机器学习

081203M04004H

Chap 7 课程作业解答

2022 年 11 月 10 号

Professor: 黄庆明



学生: 周胤昌

学号: 202228018670052

学院: 网络安全学院

所属专业: 网络安全

方向: 安全协议理论与技术

Problem 1

给定如下训练数据集

$$X = \begin{pmatrix} 3 & 4 & 1 \\ 3 & 3 & 1 \end{pmatrix}, y = (1 \quad 1 \quad -1)^T$$

通过求解 SVM 的**原始问题**来求解最大间隔的分离超平面。

Solution: 通过求解如下最优化问题来得到最优分类器的参数 (w^*, b^*) :

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|_2^2 \\ \text{s.t. } y^{(i)} (w^T x^{(i)} + b) \geq 1, i = 1, \dots, N \end{cases} \Rightarrow \begin{cases} \min_{(w_1, w_2), b} \frac{1}{2} (w_1^2 + w_2^2) \\ 3w_1 + 3w_2 + b \geq 1 \\ 4w_1 + 3w_2 + b \geq 1 \\ -(w_1 + w_2 + b) \geq 1 \end{cases}$$

要求求解这个严格的凸二次规划问题, 我们可以直接利用 Matlab 中的二次规划问题求解包直接求解. 而二次规划的标准形式为

$$\begin{cases} \min_x \frac{1}{2} x^T H x + f^T x \\ A \cdot x \leq b \end{cases}$$

对照过来, 可以知道

$$H = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}, f = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, A = \begin{pmatrix} -3 & -3 & -1 \\ -4 & -3 & -1 \\ 1 & 1 & 1 \end{pmatrix}, b = \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix}$$

于是我们可以在 Matlab 中写出如下代码:

```
1 H = [1, 0, 0; 0, 1, 0; 0, 0, 0];
2 f = [0; 0; 0];
3 A = [-3, -3, -1; -4, -3, -1; 1, 1, 1];
4 b = [-1; -1; -1];
5 [x, fval, exitflag, output, lambda] = quadprog(H, f, A, b)
```

执行后便可得到结果 (exitflag=1, 即问题存在最优解):

$$x^* = \begin{pmatrix} w_1^* \\ w_2^* \\ b^* \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.5 \\ -2 \end{pmatrix}, \min_{(w_1, w_2, b)} \frac{1}{2} (w_1^2 + w_2^2) = 0.25$$

于是最大间隔的分离超平面方程和判别函数分别为

$$\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2 = 0, f_{w,b}(x) = \text{sgn}\left(\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2\right)$$

本题的训练样本较少, 所以方法 2 是说: 可以直接观察出支持向量 (而不用求解上述二次规划问题), 从而立即得到具有最大间隔的分离超平面¹. 具体如下图 1 所示:

¹这是因为最终模型仅与**支持向量**有关.




图 1: 最大间隔分离超平面示意图

明显可以看出支持向量为 $x^{(3)}, x^{(1)}$, 所以这两个点的垂直平分线就是所要求的最大间隔分离超平面! 即其方程为 $0.5x_1 + 0.5x_2 - 2 = 0$. 而对于上述二次优化问题, 我们也可以利用拉格朗日数乘法求解如下: 构造辅助函数 (只代入支持向量, 因为最终模型只与支持向量有关)

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} (w_1^2 + w_2^2) + \alpha_1 (1 - 3w_1 - 3w_2 - b) + \alpha_2 (1 + w_1 + w_2 + b)$$

对 w_1, w_2, b 分别求偏导:

$$\begin{cases} w_1 - 3\alpha_1 + \alpha_2 = 0 \\ w_2 - 3\alpha_1 + \alpha_2 = 0 \\ -\alpha_1 + \alpha_2 = 0 \end{cases} \Rightarrow w_1 = w_2 = 2\alpha_1$$

代入辅助函数可得:

$$L(\alpha_1) = -4\alpha_1^2 + 2\alpha_1, L'(\alpha_1) = -8\alpha_1 + 2$$

令 $L'(\alpha_1) = 0$ 得 $\alpha_1 = \frac{1}{4}$, 因此 $w_1 = w_2 = \frac{1}{2}$, 从而 $b \leq -2$, 于是最大间隔的分离超平面方程为

$$\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2 = 0$$

Problem 2

给定如下训练数据集

$$X = \begin{pmatrix} 3 & 4 & 1 \\ 3 & 3 & 1 \end{pmatrix}, y = (1 \quad 1 \quad -1)^T$$

通过求解 SVM 的对偶问题来求解最大间隔的分离超平面。

Solution: SVM 的对偶问题为

$$\begin{cases} \max_{\alpha} \left\{ \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle \right\} \\ \text{s.t. } \alpha_i \geq 0, i = 1, \dots, N \\ \sum_{i=1}^N \alpha_i y^{(i)} = 0 \end{cases}$$

代入上述训练样本具体化对偶问题可得

$$\begin{cases} \max_{\alpha} \left\{ \sum_{i=1}^3 \alpha_i - \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 21\alpha_1\alpha_2 - 6\alpha_1\alpha_3 - 7\alpha_2\alpha_3) \right\} \\ \alpha_i \geq 0, i = 1, 2, 3 \\ \alpha_1 + \alpha_2 - \alpha_3 = 0 \end{cases}$$

而求解这个二次规划问题, 我们可以利用 Matlab 中的求解包来求解. 而二次规划的标准形式为

$$\begin{cases} \min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{f}^T \mathbf{x} \\ \mathbf{A} \cdot \mathbf{x} \leq \mathbf{b} \\ \mathbf{A}_{eq} \cdot \mathbf{x} = \mathbf{b}_{eq} \end{cases}$$

对照过来可以知道:

$$\mathbf{H} = \begin{pmatrix} 18 & 10.5 & -3 \\ 10.5 & 25 & -3.5 \\ -3 & -3.5 & 2 \end{pmatrix}, \mathbf{f} = \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix}$$

$$\mathbf{A} = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{pmatrix}, \mathbf{b} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \mathbf{A}_{eq} = (1 \quad 1 \quad -1), \mathbf{b}_{eq} = (0)$$

于是我们可以在 Matlab 中写出如下代码:

```
1 H = [18, 10.5, -3; 10.5, 25, -3.5; -3, -3.5, 2];
2 f = [-1; -1; -1];
3 A = [-1, 0, 0; 0, -1, 0; 0, 0, -1];
4 b = [0; 0; 0];
5 A_eq = [1, 1, -1];
6 b_eq = [0];
7 [x, fval, exitflag, output, lambda] = quadprog(H, f, A, b, A_eq, b_eq)
```

根据代码输出就可以得到对偶问题的最优解 α^* 和相应的最优值分别为

$$\alpha^* = \begin{pmatrix} 0.25 \\ 0 \\ 0.25 \end{pmatrix}, \max_{\alpha} \left\{ \sum_{i=1}^3 \alpha_i - \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 21\alpha_1\alpha_2 - 6\alpha_1\alpha_3 - 7\alpha_2\alpha_3) \right\} = 0.0625$$

于是原问题的最优解 (w^*, b^*) 为

$$w^* = \sum_{i=1}^N \alpha_i^* y^{(i)} x^{(i)} = 0.25 \cdot \begin{pmatrix} 3 \\ 3 \end{pmatrix} + 0 \cdot \begin{pmatrix} 4 \\ 3 \end{pmatrix} - 0.25 \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$$

$$b^* = y^{(j)} - \sum_{i=1}^N \alpha_i^* y^{(i)} \langle x^{(i)}, x^{(j)} \rangle, \alpha_j^* > 0 \Rightarrow b^* = y^{(1)} - \sum_{i=1}^3 \alpha_i^* y^{(i)} \langle x^{(i)}, x^{(1)} \rangle = -2$$

于是分离超平面方程和判别函数的表达式分别为

$$w^{*T} x + b^* = 0.5(x_1 + x_3) - 2 = 0, f_{w,b}(x) = \text{sgn}(w^{*T} x + b^*)$$

对于上面的对偶问题, 我们也可以解析求解: 根据约束条件可知 $\alpha_3 = \alpha_1 + \alpha_2$, 代入目标函数可得

$$\theta_D(\alpha_1, \alpha_2) = -4\alpha_1^2 - 10\alpha_1\alpha_2 - 3\alpha_2^2 + 2\alpha_1 + 2\alpha_2$$

于是

$$\frac{\partial \theta_D(\alpha_1, \alpha_2)}{\partial \alpha_1} = -8\alpha_1 - 10\alpha_2 + 2 = 0 \Rightarrow \alpha_1 = \frac{1}{4} - \frac{5\alpha_2}{4}$$

代入 $\theta_D(\alpha_1, \alpha_2)$ 可得

$$\theta_D(\alpha_2) = -\frac{1}{4}\alpha_2^2 - \frac{1}{2}\alpha_2 + \frac{1}{4} \xrightarrow{\alpha_2 \geq 0} \max_{\alpha_2 \geq 0} \theta_D = \theta_D(0) = \frac{1}{4} \Rightarrow \alpha_2 = 0, \alpha_1 = \alpha_3 = \frac{1}{4}$$

对于原问题最优解的推导与上面的过程一致, 就不赘述了. 我们也可以利用下述的算法 1 (即 SMO 算法) 来求出 SVM 的对偶问题的解为 $\alpha^* = (0.25, 0, 0.25)^T$:

Algorithm 1 SMO 算法

Input: 训练数据集 $S = \{(x^{(i)}, y^{(i)}), i = 1, \dots, N\}$, 误差 ϵ

Output: $\hat{\alpha} = (\hat{\alpha}_1, \dots, \hat{\alpha}_N)$

- 1: 初始化: $\alpha^{(0)} \leftarrow 0, k \leftarrow 0, C \leftarrow +\infty$, 并计算偏移量 $b^{(0)}$;
- 2: 初始化误差项: $E_i \leftarrow g(x^{(i)}) - y^{(i)}$;
- 3: **while** 不满足 KKT 条件且 $\exists i \in \{1, 2, \dots, N\}$, s.t. $E_i \geq \epsilon$ **do**
- 4: $k \leftarrow k + 1$ 并选择待优化的变量: $\alpha_1^{(k)}, \alpha_2^{(k)}$, 然后求解优化问题的解 $\alpha_1^{(k+1)}, \alpha_2^{(k+1)}$:

$$\alpha_2^{\text{new,unclipped}} \leftarrow \alpha_2^{(k)} + \frac{y^2(E_1 - E_2)}{\eta}, \alpha_2^{(k+1)} \leftarrow \begin{cases} H, & \text{若 } \alpha_2^{\text{new,unclipped}} > H \\ \alpha_2^{\text{new,unclipped}}, & \text{若 } L \leq \alpha_2^{\text{new,unclipped}} \leq H \\ L, & \text{若 } \alpha_2^{\text{new,unclipped}} < L \end{cases}$$

$$\eta \leftarrow K_{11} + K_{22} - 2K_{12}, \alpha_1^{(k+1)} \leftarrow \alpha_1^{(k)} + y^{(1)}y^{(2)}(\alpha_2^{(k)} - \alpha_2^{(k+1)})$$

- 5: 更新 $\alpha \leftarrow \alpha^{(k+1)}$, 更新 $E_i \leftarrow g(x^{(i)}) - y^{(i)}$, 计算 $b^{(k+1)}$;
 - 6: **end while**
 - 7: **end {SMO}**
-

Problem 3

推导软间隔 SVM 的对偶形式.

Solution: 软间隔分类器 SVM 的原问题如下:

$$\begin{cases} \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i \\ y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi_i, i = 1, \dots, N \\ \xi_i \geq 0, i = 1, \dots, N \end{cases}$$

于是我们可以构造如下的广义拉格朗日函数:

$$L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\eta}) = \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i \left[y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) - 1 + \xi_i \right] - \sum_{i=1}^N \eta_i \xi_i$$

先固定拉格朗日乘子 $\boldsymbol{\alpha}, \boldsymbol{\eta}$, 关于 \mathbf{w}, b, ξ_i 对 $L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\eta})$ 做优化(最小化)得到 $\theta_D(\boldsymbol{\alpha}, \boldsymbol{\eta})$:

$$\begin{cases} \nabla_{\mathbf{w}} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\eta}) = \mathbf{w} - \sum_{i=1}^N \alpha_i y^{(i)} \mathbf{x}^{(i)} = 0 \\ \frac{\partial}{\partial b} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\eta}) = - \sum_{i=1}^N \alpha_i y^{(i)} = 0 \\ \frac{\partial}{\partial \xi_i} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\eta}) = C - \alpha_i - \eta_i = 0 \end{cases}$$

将上述 3 个条件代入广义拉格朗日函数可得到 $\theta_D(\boldsymbol{\alpha}, \boldsymbol{\eta})$:

$$\begin{aligned} \theta_D(\boldsymbol{\alpha}, \boldsymbol{\eta}) &= \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i \left[y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) - 1 + \xi_i \right] - \sum_{i=1}^N \eta_i \xi_i \\ &= \frac{1}{2} \sum_{i=1}^N \alpha_i y^{(i)} (\mathbf{x}^{(i)})^T \sum_{j=1}^N \alpha_j y^{(j)} \mathbf{x}^{(j)} - \sum_{i=1}^N \alpha_i \left[y^{(i)} \left(\sum_{j=1}^N \alpha_j y^{(j)} (\mathbf{x}^{(j)})^T \mathbf{x}^{(i)} + b \right) - 1 + \xi_i \right] \\ &\quad + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \eta_i \xi_i \\ &= \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle - \sum_{i,j=1}^N \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle - b \cdot \sum_{i=1}^N \alpha_i y^{(i)} \\ &\quad + \sum_{i=1}^N \alpha_i + \sum_{i=1}^N (C - \alpha_i - \eta_i) \xi_i \\ &= -\frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle + \sum_{i=1}^N \alpha_i \end{aligned}$$

即得到

$$\theta_D(\boldsymbol{\alpha}, \boldsymbol{\eta}) = \min_{\mathbf{w}, b, \boldsymbol{\xi}} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\eta}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle = \theta_D(\boldsymbol{\alpha})$$

于是最大化 $\theta_D(\alpha)$, 即可得出下述的对偶问题:

$$\begin{cases} \max_{\alpha} \left\{ \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle \right\} \\ \sum_{i=1}^N \alpha_i y^{(i)} = 0 \\ 0 \leq \alpha_i = \underbrace{C - \eta_i}_{\because \eta_i \geq 0 (\text{乘子非负})} \leq C, i = 1, \dots, N \end{cases}$$

假设 $\alpha^* = (\alpha_1^*, \dots, \alpha_N^*)$ 是上述对偶问题的最优解, 那么原问题的解可以如下求解: 显然 \mathbf{w}^* 可以直接写出:

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y^{(i)} \mathbf{x}^{(i)}$$

而对于 b^* , 需要找到一个相关的等式, 而根据库恩塔克条件 (KKT) 可得

$$\alpha_i \left[y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) - 1 + \xi_i \right] = 0, \eta_i \xi_i = 0$$

因此若想要得到 b 的等式, 则根据互补松弛性可知, 只需要 $\alpha_i > 0 (\neq 0)$, 但是 ξ_i 又是不能知道的, 所以需要想办法把它去掉 (即需要使得 $\xi_i = 0$), 于是又根据互补松弛性可知, 再需要令 $\eta_i > 0 (\neq 0)$ 即可使得 $\xi_i = 0$, 从而可得出 b 的等式

$$y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) = 1 \Rightarrow b = y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)}$$

因此若想求得 b^* , 则需要挑选样本 $(\mathbf{x}^{(j)}, y^{(j)})$, 使得样本满足 $\alpha_j^* > 0, \eta_j > 0$ (即 $0 < \alpha_j^* < C$), 于是可求得

$$b^* = y^{(j)} - \mathbf{w}^T \mathbf{x}^{(j)} = y^{(j)} - \sum_{i=1}^N \alpha_i^* y^{(i)} (\mathbf{x}^{(i)})^T \mathbf{x}^{(j)} = y^{(j)} - \sum_{i=1}^N \alpha_i^* y^{(i)} \langle \mathbf{x}^{(i)}, \mathbf{x}^{(j)} \rangle$$

于是可求得分类超平面方程和判别函数分别为

$$(\mathbf{w}^*)^T \mathbf{x} + b^* = 0, f_{\mathbf{w},b}(\mathbf{x}) = \text{sgn} \{ (\mathbf{w}^*)^T \mathbf{x} + b^* \}$$

Problem 4

高斯核的形式如下

$$\mathcal{K}(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right)$$

请证明高斯核可以表示为无限维特征向量的内积。

Solution: 可以将高斯核作如下展开:

$$\begin{aligned}\mathcal{K}(\mathbf{x}, \mathbf{z}) &= \exp\left\{-\frac{(\mathbf{x} - \mathbf{z})^\top (\mathbf{x} - \mathbf{z})}{2\sigma^2}\right\} \\ &= \exp\left\{-\frac{\mathbf{x}^\top \mathbf{x} - 2\mathbf{x}^\top \mathbf{z} + \mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right\} \\ &= \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2\sigma^2}\right) \cdot \exp\left(\frac{\mathbf{x}^\top \mathbf{z}}{\sigma^2}\right) \cdot \exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right)\end{aligned}$$

由于指数函数 $y = e^x$ 的泰勒级数在任一点 (实数) 都收敛, 所以我们可以将上式的中间项做泰勒展开:

$$\exp\left(\frac{\mathbf{x}^\top \mathbf{z}}{\sigma^2}\right) = \sum_{n=0}^{\infty} \frac{\left(\frac{\mathbf{x}^\top \mathbf{z}}{\sigma^2}\right)^n}{n!} = \sum_{n=0}^{\infty} \frac{(\mathbf{x}^\top \mathbf{z})^n}{n! \sigma^{2n}}$$

于是核函数可以表示为

$$\mathcal{K}(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2\sigma^2}\right) \cdot \exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right) \cdot \sum_{n=0}^{\infty} \frac{(\mathbf{x}^\top \mathbf{z})^n}{n! \sigma^{2n}}$$

不妨设 $\mathbf{x}^\top \mathbf{z} = \sum_{i=1}^k x_i z_i$. 为了进行后续推导, 我们需要声明一下**推广的二项式定理**, 即

$$\left(\sum_{i=1}^k x_i\right)^n = \sum_{l=1}^L \frac{n!}{n_{l_1}! \cdot n_{l_2}! \cdots n_{l_k}!} x_1^{n_{l_1}} \cdot x_2^{n_{l_2}} \cdots x_k^{n_{l_k}}$$

其中 $\sum_{i=1}^k n_{l_i} = n, L = \frac{(n+k-1)!}{n!(k-1)!}$ (L 也被称作多项式系数). 于是有:

$$\begin{aligned}\mathcal{K}(\mathbf{x}, \mathbf{z}) &= \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2\sigma^2}\right) \cdot \exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right) \cdot \sum_{n=0}^{\infty} \frac{(\mathbf{x}^\top \mathbf{z})^n}{n! \sigma^{2n}} \\ &= \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2\sigma^2}\right) \cdot \exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right) \cdot \sum_{n=0}^{\infty} \frac{1}{n! \sigma^{2n}} \sum_{l=1}^L \frac{n!}{n_{l_1}! \cdot n_{l_2}! \cdots n_{l_k}!} (x_1 z_1)^{n_{l_1}} \cdot (x_2 z_2)^{n_{l_2}} \cdots (x_k z_k)^{n_{l_k}} \\ &= \sum_{n=0}^{\infty} \sum_{l=1}^L \frac{\exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2\sigma^2}\right) \cdot \exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right)}{\sigma^{2n} \cdot n_{l_1}! \cdot n_{l_2}! \cdots n_{l_k}!} \left(x_1^{n_{l_1}} \cdot x_2^{n_{l_2}} \cdots x_k^{n_{l_k}}\right) \cdot \left(z_1^{n_{l_1}} \cdot z_2^{n_{l_2}} \cdots z_k^{n_{l_k}}\right) \\ &= \sum_{n=0}^{\infty} \sum_{l=1}^L \underbrace{\frac{\exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2\sigma^2}\right)}{\sqrt{\sigma^{2n} \cdot n_{l_1}! \cdot n_{l_2}! \cdots n_{l_k}!}} \left(x_1^{n_{l_1}} \cdot x_2^{n_{l_2}} \cdots x_k^{n_{l_k}}\right)}_{:=\varphi_{n_l}(\mathbf{x})} \cdot \underbrace{\frac{\exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2\sigma^2}\right)}{\sqrt{\sigma^{2n} \cdot n_{l_1}! \cdot n_{l_2}! \cdots n_{l_k}!}} \left(z_1^{n_{l_1}} \cdot z_2^{n_{l_2}} \cdots z_k^{n_{l_k}}\right)}_{:=\varphi_{n_l}(\mathbf{z})} \\ &= \sum_{n=0}^{\infty} \sum_{l=1}^L \varphi_{n_l}(\mathbf{x}) \cdot \varphi_{n_l}(\mathbf{z})\end{aligned}$$

我们令

$$\Phi_n(\mathbf{x}) = [\varphi_{n_1}(\mathbf{x}), \varphi_{n_2}(\mathbf{x}), \dots, \varphi_{n_L}(\mathbf{x})], \Phi_n(\mathbf{z}) = [\varphi_{n_1}(\mathbf{z}), \varphi_{n_2}(\mathbf{z}), \dots, \varphi_{n_L}(\mathbf{z})]$$

再令

$$\mathcal{K}_n(\mathbf{x}, \mathbf{z}) = \langle \Phi_n(\mathbf{x}), \Phi_n(\mathbf{z}) \rangle$$

于是有

$$\mathcal{K}(\mathbf{x}, \mathbf{z}) = \sum_{n=0}^{\infty} \sum_{l=1}^L \varphi_{n_l}(\mathbf{x}) \cdot \varphi_{n_l}(\mathbf{z}) = \sum_{n=0}^{\infty} \langle \Phi_n(\mathbf{x}), \Phi_n(\mathbf{z}) \rangle = \sum_{n=0}^{\infty} \mathcal{K}_n(\mathbf{x}, \mathbf{z})$$

显然高斯核可以表示为无限维特征向量的内积, 而且可知高斯核也可以表示成无限个核函数的线性组合.

Problem 5

请证明, 无论数据空间的维数如何, 仅由两个数据点 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$ (每个类一个样本) 所组成的数据集足以确定最大间隔超平面. 充分解释你的答案, 包括给出硬间隔 SVM (即 \mathbf{w}) 作为 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$ 函数的解的明确公式.

Solution: 显然两个样本都是支持向量, 所以这两个点的垂直平分超平面即为硬间隔 SVM 的表达式. 不妨设 $\mathbf{x}^{(1)} = (x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)})^T$, $\mathbf{x}^{(2)} = (x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)})^T$, 先计算这两点连线的方向向量, 也就是垂直平分超平面的法向量:

$$\mathbf{n} = \mathbf{w} = \mathbf{x}^{(1)} - \mathbf{x}^{(2)} = (x_1^{(1)} - x_1^{(2)}, x_2^{(1)} - x_2^{(2)}, \dots, x_n^{(1)} - x_n^{(2)})^T$$

而垂直平分超平面一定经过这两点连线的中点, 即

$$\mathbf{P}_0 = \frac{\mathbf{x}^{(1)} + \mathbf{x}^{(2)}}{2} = \frac{1}{2} (x_1^{(1)} + x_1^{(2)}, x_2^{(1)} + x_2^{(2)}, \dots, x_n^{(1)} + x_n^{(2)})^T$$

于是根据点法式即可写出如下垂直平分超平面的方程:

$$\mathbf{w}^T \mathbf{x} + b = 0 = \sum_{i=1}^n (x_i^{(1)} - x_i^{(2)}) x_i + b = 0 \xrightarrow{\text{代入点 } \mathbf{P}_0} b = - \sum_{i=1}^n \frac{1}{2} (x_i^{(1)} + x_i^{(2)}) (x_i^{(1)} - x_i^{(2)})$$

于是最大间隔超平面方程为:

$$\mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^n (x_i^{(1)} - x_i^{(2)}) \left[x_i - \frac{1}{2} (x_i^{(1)} + x_i^{(2)}) \right] = 0$$



中国科学院大学
University of Chinese Academy of Sciences